

Trabajo Práctico N°1

Fuentealba Leonardo, Zuñiga Fernando

Table of contents

1	Ejercicio 1. Emergencia de plántulas	2
1.1	Frecuencia por especie y tratamiento	3
1.2	Fecha y frecuencia en el tiempo	3
1.3	Transformación logarítmica	4
1.4	Media, desvío y CV	4
1.5	Gráfico por especie y tratamiento	5
1.6	Especies no identificadas	6
1.7	Especies más frecuentes	6
2	Ejercicio 2. Encuesta	8
2.1	Tibble vs data.frame	8
2.2	Consumo de alcohol	9
2.3	Histograma de edad	9
2.4	Exceso de alcohol	10
2.5	Otras variables de consumo	12
3	Ejercicio 3. COVID-19	14
3.1	Fecha	16
3.2	Casos diarios en Argentina	16
3.3	Comparación por millón de habitantes	17
3.4	Fallecimientos en Argentina	18
3.5	Patrón trimestral y mensual	20
3.6	Comparación entre países del Cono Sur	22
4	Ejercicio 4. Telefonía fija ENACOM	25
4.1	Resumen descriptivo	26
4.2	Evolución anual	26
4.3	Evolución trimestral	27
4.4	Proporción por tipo de cliente	28
4.5	Accesos por provincia	28

5 Ejercicio 5. ARPU de telefonía móvil	30
5.1 ARPU nominal (2020-2025)	31
5.2 Tipo de cambio y ARPU en dólares	32
6 Respuestas	34
6.1 Ejercicio 1	34
6.2 Ejercicio 4	35
6.3 Ejercicio 5	35

```
library(tidyverse)
library(readxl)
library(httr2)
library(lubridate)
```

1 Ejercicio 1. Emergencia de plántulas

Pastoreo vs. clausura (sep-2013 a sep-2014).

```
if (!file.exists("elcuy.csv")) {
  stop("No se encontró 'elcuy.csv' en: ", getwd())
}

datos_cuy <- read_delim(
  "elcuy.csv",
  delim = ";",
  locale = locale(decimal_mark = ","),
  show_col_types = FALSE
)

names(datos_cuy)[6] <- "Anio"
glimpse(datos_cuy)
```

```
Rows: 117
Columns: 10
$ Especie      <chr> "Senecio filaginoides", "Gilia sp", "Ranunculacea sp", "Pap~
$ emergencia  <dbl> 1, 2, 2, 1, 1, 1, 5, 3, 1, 1, 1, 1, 1, 17, 18, 1, 3, 2, 6, ~
$ densidad    <dbl> 1, 2, 2, 1, 1, 1, 5, 3, 1, 1, 1, 1, 1, 17, 18, 1, 3, 2, 6, ~
$ Pastoreo    <chr> "Sin pastoreo", "Sin pastoreo", "Sin pastoreo", "Sin pastor~
$ Transecta   <dbl> 1, 1, 1, 1, 2, 2, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 1, 1, 1, 1, ~
$ Anio        <dbl> 13, 13, 13, 13, 13, 13, 13, 13, 13, 13, 13, 13, 13, 13, ~
```

```
$ mes      <dbl> 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 9, 11, 11, 11,~
$ parche   <dbl> 0, 1, 1, 1, 1, 1, 0, 1, 0, 1, 1, 0, 0, 1, 1, 1, 0, 0, 1, 1,~
$ hum_sup  <dbl> 11.67, 9.11, 9.11, 9.11, 9.47, 9.47, 16.55, 12.99, 16.55, 1~
$ hum_prof <dbl> 11.17, 8.64, 8.64, 8.64, 9.29, 9.29, 8.28, 8.70, 8.28, 8.70~
```

1.1 Frecuencia por especie y tratamiento

```
frec_especie_pastoreo <- datos_cuy %>%
  group_by(Pastoreo, Especie) %>%
  summarise(frecuencia = sum(emergencia), .groups = "drop") %>%
  arrange(desc(frecuencia))
```

```
frec_especie_pastoreo
```

```
# A tibble: 30 x 3
  Pastoreo   Especie      frecuencia
  <chr>      <chr>      <dbl>
1 Pastoreo   Gilia sp      180
2 Pastoreo   Ranunculacea sp 167
3 Sin pastoreo Gilia sp      87
4 Sin pastoreo Pappostipa sp 71
5 Pastoreo   Pappostipa sp 56
6 Sin pastoreo Plantago patagonica 51
7 Sin pastoreo Ranunculacea sp 18
8 Pastoreo   Bromus catharticus 14
9 Sin pastoreo Grindelia chiloensis 9
10 Pastoreo   Plantago patagonica 8
# i 20 more rows
```

1.2 Fecha y frecuencia en el tiempo

```
datos_cuy <- datos_cuy %>%
  mutate(
    Anio_completo = 2000 + Anio,
    fecha = make_date(year = Anio_completo, month = mes, day = 1)
  )

frec_tiempo <- datos_cuy %>%
```

```
group_by(Pastoreo, Especie, fecha) %>%
summarise(frecuencia = sum(emergencia), .groups = "drop") %>%
arrange(fecha, Pastoreo, desc(frecuencia))

frec_tiempo
```

```
# A tibble: 63 x 4
  Pastoreo   Especie      fecha      frecuencia
  <chr>      <chr>      <date>      <dbl>
1 Pastoreo Ranunculacea sp 2013-09-01      26
2 Pastoreo Gilia sp    2013-09-01      17
3 Pastoreo Pappostipa sp  2013-09-01       2
4 Pastoreo Euphorbia colina 2013-09-01       1
5 Pastoreo Senecio filaginoides 2013-09-01       1
6 Pastoreo Sp2        2013-09-01       1
7 Pastoreo Sp3        2013-09-01       1
8 Sin pastoreo Gilia sp    2013-09-01       3
9 Sin pastoreo Ranunculacea sp 2013-09-01       3
10 Sin pastoreo Pappostipa sp 2013-09-01       1
# i 53 more rows
```

1.3 Transformación logarítmica

Usamos $\log(x + 1)$ para evitar $\log(0)$.

```
datos_cuy <- datos_cuy %>%
  mutate(log_emergencia = log(emergencia + 1))
```

1.4 Media, desvío y CV


```
resumen_especie_fecha <- datos_cuy %>%
  group_by(Especie, fecha) %>%
  summarise(
    media_log = mean(log_emergencia),
    de_log    = sd(log_emergencia),
    cv_log    = ifelse(media_log == 0, NA_real_, de_log / media_log * 100),
    .groups = "drop"
  ) %>%
  arrange(fecha, Especie)
```

```
resumen_especie_fecha
```

```
# A tibble: 41 x 5
  Especie      fecha      media_log de_log cv_log
  <chr>      <date>      <dbl>  <dbl>  <dbl>
1 Euphorbia colina 2013-09-01    0.693 NA      NA
2 Gilia sp       2013-09-01    1.56  1.17   74.9
3 Pappostipa sp   2013-09-01    0.693 0      0
4 Ranunculacea sp 2013-09-01    1.58  0.861  54.4
5 Senecio filaginoides 2013-09-01    0.693 0      0
6 Sp2           2013-09-01    0.693 NA      NA
7 Sp3           2013-09-01    0.693 NA      NA
8 Gilia sp       2013-11-01    1.13  0.459  40.5
9 Grindelia chiloensis 2013-11-01    0.896 0.287  32.0
10 Habranthus jamesonii 2013-11-01    0.693 NA      NA
# i 31 more rows
```

1.5 Gráfico por especie y tratamiento

```
datos_cuy %>%
  group_by(Pastoreo, Especie) %>%
  summarise(emergencia_total = sum(emergencia), .groups = "drop") %>%
  ggplot(aes(x = reorder(Especie, emergencia_total), y = emergencia_total, fill = Pastoreo))
  geom_col(position = "dodge") +
  coord_flip() +
  labs(
    title = "Emergencia total de plántulas por especie y tratamiento",
    x = "Especie", y = "Emergencia total", fill = "Tratamiento"
  ) +
  theme_minimal()
```



1.6 Especies no identificadas

```
datos_cuy <- datos_cuy %>%
  mutate(
    no_identificada = str_detect(Especie, regex("^Sp\\d+", ignore_case = TRUE)),
    Especie = if_else(no_identificada, "No identificada", str_trim(Especie))
  )
```

1.7 Especies más frecuentes


```
especies_top <- datos_cuy %>%
  group_by(Especie) %>%
  summarise(total = sum(emergencia), .groups = "drop") %>%
  slice_max(total, n = 4) %>%
  pull(Especie)

datos_cuy %>%
```

```

filter(Especie %in% especies_top) %>%
group_by(Especie, Pastoreo, fecha) %>%
summarise(emergencia_media = mean(emergencia), .groups = "drop") %>%
ggplot(aes(x = fecha, y = emergencia_media, color = Pastoreo)) +
geom_line(linewidth = 1) +
geom_point(size = 2) +
facet_wrap(~Especie, scales = "free_y") +
labs(
  title = "Emergencia media mensual de las especies más frecuentes",
  subtitle = "Según tratamiento de pastoreo",
  x = "Fecha de muestreo",
  y = "Emergencia media (plántulas/cuadro)",
  color = "Tratamiento"
) +
theme_minimal() +
theme(legend.position = "bottom")

```



2 Ejercicio 2. Encuesta

```
if (!file.exists("encuesta.csv")) {  
  stop("No se encontró 'encuesta.csv' en: ", getwd())  
}  
  
datos_encuesta <- suppressMessages(  
  read_delim("encuesta.csv", delim = ";", show_col_types = FALSE)  
)  
  
datos_sel <- datos_encuesta %>% select(8:11, 47:51)
```

El archivo trae columnas repetidas (Hora, Comida, Bebida); readr les agrega un sufijo.

2.1 Tibble vs data.frame

```
tibble_datos <- as_tibble(datos_sel)  
df_datos <- as.data.frame(datos_sel)  
tibble_datos
```

```
# A tibble: 559 x 9  
  Año Curso Sexo      Edad consumiste_alcohol consumiste_alcohol_este_anio  
  <dbl> <dbl> <chr>    <dbl> <chr>                                <chr>  
1     3     1 Masculino    18 Sí                                Sí  
2     4     1 Femenino    17 Sí                                Sí  
3     1     1 Masculino    13 Sí                                Sí  
4     3     1 Masculino    17 Sí                                Sí  
5     4     1 Masculino    17 Sí                                Sí  
6     3     1 Femenino    18 Sí                                Sí  
7     4     1 Masculino    17 Sí                                Sí  
8     1     1 Masculino    14 Sí                                Sí  
9     3     1 Femenino    17 No                                No  
10    4     1 Femenino    17 Sí                                Sí  
# i 549 more rows  
# i 3 more variables: consumiste_alcohol_este_mes <chr>,  
#   consumiste_alcohol_esta_semana <chr>, tuviste_un_exceso_de_alcohol <chr>
```

El tibble muestra las primeras filas y el tipo de cada columna. El data.frame imprime todo y no muestra el tipo. El contenido es el mismo.

2.2 Consumo de alcohol

```
alcohol_si <- datos_sel %>% filter(consumiste_alcohol == "Sí")

pct_total_alcohol <- nrow(alcohol_si) / nrow(datos_sel) * 100
pct_total_alcohol
```

```
[1] 89.26655
```

```
alcohol_por_sexo <- alcohol_si %>%
  count(Sexo, name = "frecuencia_absoluta") %>%
  mutate(frecuencia_relativa = frecuencia_absoluta / sum(frecuencia_absoluta) * 100)


alcohol_por_sexo
```

```
# A tibble: 3 x 3
  Sexo      frecuencia_absoluta frecuencia_relativa
<chr>          <int>          <dbl>
1 Femenino         237          47.5
2 Masculino        260          52.1
3 <NA>              2           0.401
```

2.3 Histograma de edad

```
alcohol_si %>%
  filter(!is.na(Sexo)) %>%
  ggplot(aes(x = Edad, fill = Sexo)) +
  geom_histogram(binwidth = 1, color = "white", boundary = 0) +
  facet_wrap(~Sexo, ncol = 1) +
  labs(
    title = "Distribución de edad de quienes consumieron alcohol",
    subtitle = "Comparado por sexo",
    x = "Edad", y = "Cantidad de estudiantes"
  ) +
  theme_minimal() +
  theme(legend.position = "none")
```

Distribución de edad de quienes consumieron alcohol
Comparado por sexo



2.4 Exceso de alcohol

```
pct_exceso_total <- mean(datos_sel$tuviste_un_exceso_de_alcohol == "Sí", na.rm = TRUE) * 100
pct_exceso_total
```

```
[1] 42.39714
```

```
datos_sel <- datos_sel %>%
  mutate(
    Nivel = case_when(
      Año %in% 1:3 ~ "Básico",
      Año %in% 4:6 ~ "Superior",
      TRUE ~ NA_character_
    )
  )

resumen_exceso_nivel <- datos_sel %>%
  filter(!is.na(Sexo), !is.na(Nivel)) %>%
```

```

group_by(Sexo, Nivel) %>%
summarise(
  total = n(),
  afirmativos = sum(tuviste_un_exceso_de_alcohol == "Sí", na.rm = TRUE),
  porcentaje = afirmativos / total * 100,
  .groups = "drop"
)

resumen_exceso_nivel

```

```


# A tibble: 4 x 5
  Sexo      Nivel  total afirmativos porcentaje
  <chr>    <chr>   <int>      <int>      <dbl>
1 Femenino Básico    168         71      42.3
2 Femenino Superior   90         52      57.8
3 Masculino Básico    200         60       30
4 Masculino Superior   98         53      54.1

```

```

resumen_exceso_nivel %>%
  ggplot(aes(x = Nivel, y = porcentaje, fill = Sexo)) +
  geom_col(position = "dodge") +
  labs(
    title = "% de exceso de alcohol declarado, por sexo y nivel educativo",
    x = "Nivel educativo",
    y = "% de respuestas afirmativas",
    fill = "Sexo"
  ) +
  theme_minimal()

```



2.5 Otras variables de consumo

```
vars_consumo <- c(
  "consumiste_alcohol_este_anio",
  "consumiste_alcohol_este_mes",
  "consumiste_alcohol_esta_semana",
  "tuviste_un_exceso_de_alcohol"
)


resumen_consumo <- datos_sel %>%
  filter(!is.na(Sexo)) %>%
  select(Sexo, all_of(vars_consumo)) %>%
  pivot_longer(
    cols = all_of(vars_consumo),
    names_to = "variable",
    values_to = "respuesta"
  ) %>%
  filter(respuesta == "Sí") %>%
  count(variable, Sexo, name = "frecuencia")
```

```
resumen_consumo
```

```
# A tibble: 8 x 3
```

	variable	Sexo	frecuencia
	<chr>	<chr>	<int>
1	consumiste_alcohol_esta_semana	Femenino	143
2	consumiste_alcohol_esta_semana	Masculino	151
3	consumiste_alcohol_este_anio	Femenino	230
4	consumiste_alcohol_este_anio	Masculino	244
5	consumiste_alcohol_este_mes	Femenino	188
6	consumiste_alcohol_este_mes	Masculino	208
7	tuviste_un_exceso_de_alcohol	Femenino	123
8	tuviste_un_exceso_de_alcohol	Masculino	113

```
resumen_consumo %>%  
  ggplot(aes(x = variable, y = frecuencia, color = Sexo)) +  
  geom_linerange(aes(ymin = 0, ymax = frecuencia),  
                 position = position_dodge(width = 0.4), linewidth = 1) +  
  geom_point(position = position_dodge(width = 0.4), size = 3) +  
  coord_flip() +  
  labs(  
    title = "Respuestas afirmativas por variable de consumo y sexo",  
    x = NULL, y = "Cantidad de respuestas 'Sí'",  
    color = "Sexo"  
  ) +  
  theme_minimal()
```



3 Ejercicio 3. COVID-19

```
if (!file.exists("cases_deaths.csv")) {
  stop("No se encontró 'cases_deaths.csv' en: ", getwd())
}

países_cono_sur <- c(
  "Argentina", "Chile", "Brazil", "Uruguay",
  "Bolivia", "Paraguay", "Peru"
)

datos_covid <- read_csv_chunked(
  "cases_deaths.csv",
  callback = DataFrameCallback$new(function(chunk, pos) {
    filter(chunk, country %in% países_cono_sur)
  }),
  chunk_size = 50000,
  show_col_types = FALSE
)
```

```
)
```

```
glimpse(datos_covid)
```

```
Rows: 16,723
```

```
Columns: 40
```

```
$ country
```

```
<chr> "Argentina", "Argentina", "Arg~
```

```
$ date
```

```
<date> 2020-01-04, 2020-01-05, 2020-
```

```
~
```

```
$ new_cases
```

```
<dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
```

```
$ total_cases
```

```
<dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
```

```
$ new_deaths
```

```
<dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
```

```
$ total_deaths
```

```
<dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
```

```
$ weekly_cases
```

```
<dbl> NA, NA, NA, NA, NA, 0, 0, 0, 0, ~
```

```
$ weekly_deaths
```

```
<dbl> NA, NA, NA, NA, NA, 0, 0, 0, 0, ~
```

```
$ weekly_pct_growth_cases
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ weekly_pct_growth_deaths
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ biweekly_cases
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ biweekly_deaths
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ biweekly_pct_growth_cases
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ biweekly_pct_growth_deaths
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ new_cases_per_million
```

```
<dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
```

```
$ new_deaths_per_million
```

```
<dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
```

```
$ total_cases_per_million
```

```
<dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
```

```
$ total_deaths_per_million
```

```
<dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
```

```
$ weekly_cases_per_million
```

```
<dbl> NA, NA, NA, NA, NA, 0, 0, 0, 0, ~
```

```
$ weekly_deaths_per_million
```

```
<dbl> NA, NA, NA, NA, NA, 0, 0, 0, 0, ~
```

```
$ biweekly_cases_per_million
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ biweekly_deaths_per_million
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ total_deaths_per_100k
```

```
<dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
```

```
$ new_deaths_per_100k
```

```
<dbl> 0, 0, 0, 0, 0, 0, 0, 0, 0, 0, ~
```

```
$ new_cases_7_day_avg_right
```

```
<dbl> NA, NA, NA, NA, NA, 0, 0, 0, 0, ~
```

```
$ new_deaths_7_day_avg_right
```

```
<dbl> NA, NA, NA, NA, NA, 0, 0, 0, 0, ~
```

```
$ new_cases_per_million_7_day_avg_right
```

```
<dbl> NA, NA, NA, NA, NA, 0, 0, 0, 0, ~
```

```
$ new_deaths_per_million_7_day_avg_right
```

```
<dbl> NA, NA, NA, NA, NA, 0, 0, 0, 0, ~
```

```
$ new_deaths_per_100k_7_day_avg_right
```

```
<dbl> NA, NA, NA, NA, NA, 0, 0, 0, 0, ~
```

```
$ cfr
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ cfr_100_cases
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ cfr_short_term
```

```
<dbl> NA, NA, NA, NA, NA, NA, NA, NA, ~
```

```
$ days_since_100_total_cases
```

```
<dbl> -69, -68, -67, -66, -65, -
```

```
64, ~
```

```

$ days_since_5_total_deaths      <dbl> -69, -68, -67, -66, -65, -
64, ~
$ days_since_1_total_cases_per_million <dbl> -68, -67, -66, -65, -64, -
63, ~
$ days_since_0_1_total_deaths_per_million <dbl> -69, -68, -67, -66, -65, -
64, ~
$ days_since_100_total_cases_and_5m_pop <dbl> -69, -68, -67, -66, -65, -
64, ~
$ total_deaths_last12m           <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA~
$ total_deaths_per_100k_last12m    <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA~
$ total_deaths_per_million_last12m <dbl> NA, NA, NA, NA, NA, NA, NA, NA, NA~

```

```

datos_covid %>%
  summarise(
    na_new_cases = sum(is.na(new_cases)),
    na_new_deaths = sum(is.na(new_deaths))
  )

```

```

# A tibble: 1 x 2
  na_new_cases na_new_deaths
    <int>         <int>
1         2             2

```

3.1 Fecha

```

datos_covid <- datos_covid %>% mutate(date = as_date(date))
class(datos_covid$date)

```

```
[1] "Date"
```

```
range(datos_covid$date)
```

```
[1] "2020-01-04" "2026-07-19"
```

El rango disponible va desde el 4 de enero de 2020 hasta el 19 de julio de 2026.


3.2 Casos diarios en Argentina

```

argentina <- datos_covid %>% filter(country == "Argentina")

argentina %>%
  ggplot(aes(x = date)) +
  geom_line(aes(y = new_cases), color = "grey70", linewidth = 0.3) +
  geom_line(aes(y = new_cases_7_day_avg_right), color = "steelblue", linewidth = 0.8) +
  labs(
    title = "Casos diarios confirmados de COVID-19 - Argentina",
    subtitle = "Gris: dato diario | Azul: promedio móvil 7 días",
    x = "Fecha", y = "Casos nuevos por día"
  ) +
  theme_minimal()

```




3.3 Comparación por millón de habitantes

```

datos_covid %>%
  filter(country %in% c("Argentina", "Chile", "Brazil", "Uruguay")) %>%
  ggplot(aes(x = date, y = new_cases_per_million_7_day_avg_right, color = country)) +

```

```
geom_line(linewidth = 0.7) +
labs(
  title = "Casos diarios de COVID-19 por millón de habitantes",
  subtitle = "Promedio móvil de 7 días",
  x = "Fecha", y = "Casos nuevos por millón de hab.",
  color = "País"
) +
theme_minimal()
```




3.4 Fallecimientos en Argentina

```
argentina %>%
  ggplot(aes(x = date)) +
  geom_line(aes(y = new_deaths), color = "grey70", linewidth = 0.3) +
  geom_line(aes(y = new_deaths_7_day_avg_right), color = "firebrick", linewidth = 0.8) +
  labs(
    title = "Fallecimientos diarios por COVID-19 - Argentina",
    subtitle = "Gris: dato diario | Rojo: promedio móvil 7 días",
```


```
x = "Fecha", y = "Fallecimientos por día"
) +
theme_minimal()
```

Fallecimientos diarios por COVID-19 — Argentina

Gris: dato diario | Rojo: promedio móvil 7 días




```
argentina %>%
  ggplot(aes(x = date, y = total_deaths)) +
  geom_line(color = "firebrick", linewidth = 0.8) +
  labs(
    title = "Fallecimientos acumulados por COVID-19 - Argentina",
    x = "Fecha", y = "Fallecimientos acumulados"
  ) +
  theme_minimal()
```




3.5 Patrón trimestral y mensual

```
argentina <- argentina %>%
  mutate(
    anio = year(date),
    trimestre = quarter(date),
    mes = month(date, label = TRUE, abbr = TRUE)
  )

argentina %>%
  group_by(anio, trimestre) %>%
  summarise(muertes_trimestre = sum(new_deaths, na.rm = TRUE), .groups = "drop") %>%
  ggplot(aes(x = factor(trimestre), y = muertes_trimestre, fill = factor(anio))) +
  geom_col(position = "dodge") +
  labs(
    title = "Fallecimientos por trimestre - Argentina",
    x = "Trimestre", y = "Fallecimientos del trimestre", fill = "Año"
  ) +
  theme_minimal()
```



```
argentina %>%
  ggplot(aes(x = mes, y = new_deaths)) +
  geom_boxplot(fill = "salmon", outlier.alpha = 0.3) +
  labs(
    title = "Fallecimientos diarios según mes del año - Argentina",
    subtitle = "Todos los años combinados",
    x = "Mes", y = "Fallecimientos por día"
  ) +
  theme_minimal()
```



3.6 Comparación entre países del Cono Sur

```
países_comparar <- c("Argentina", "Chile", "Peru", "Bolivia", "Paraguay", "Brazil")


total_por_pais <- datos_covid %>%
  filter(country %in% países_comparar) %>%
  group_by(country) %>%
  filter(date == max(date)) %>%
  ungroup() %>%
  select(country, total_deaths, total_deaths_per_100k)

total_por_pais
```

```
# A tibble: 6 x 3
  country total_deaths total_deaths_per_100k
  <chr>      <dbl>          <dbl>
1 Argentina 130850          288.
2 Bolivia   22389          185.
3 Brazil    704045         335.
```


4	Chile	62893	322.
5	Paraguay	19880	294.
6	Peru	221072	660.

```
total_por_pais %>%
  ggplot(aes(x = reorder(country, total_deaths), y = total_deaths)) +
  geom_col(fill = "darkred") +
  coord_flip() +
  labs(
    title = "Fallecidos totales por COVID-19 - Cono Sur",
    x = "País", y = "Fallecidos totales"
  ) +
  theme_minimal()
```




```
total_por_pais %>%
  ggplot(aes(x = reorder(country, total_deaths_per_100k), y = total_deaths_per_100k)) +
  geom_col(fill = "darkorange") +
  coord_flip() +
  labs(
    title = "Fallecidos cada 100.000 habitantes",
```

```
x = "País", y = "Fallecidos cada 100.000 hab."
) +
theme_minimal()
```



```
datos_covid %>%
  filter(country %in% paises_comparar) %>%
  ggplot(aes(x = date, y = total_deaths_per_million, color = country)) +
  geom_line(linewidth = 0.7) +
  labs(
    title = "Fallecidos acumulados por millón de habitantes",
    x = "Fecha", y = "Fallecidos acumulados por millón",
    color = "País"
  ) +
  theme_minimal()
```



4 Ejercicio 4. Telefonía fija ENACOM

```

archivo_totales    <- "Telefonía Fija Accesos Totales.xlsx"
archivo_provincias <- "Telefonía Fija Accesos Provincias.xlsx"

if (!file.exists(archivo_totales) || !file.exists(archivo_provincias)) {
  stop("Faltan los Excel de telefonía fija en: ", getwd())
}

telefonía_fija <- read_excel(archivo_totales, skip = 1)

telefonía_fija_limpia <- telefonía_fija %>%
  mutate(
    across(c(Hogares, Comercial, Total), ~ as.numeric(str_remove_all(as.character(.), "[.,]")))
    across(c(Gobierno, Otros), ~ round(. * 1000))
  ) %>%
  mutate(Total_calculado = Hogares + Comercial + Gobierno + Otros)

glimpse(telefonía_fija_limpia)

```

```

Rows: 49
Columns: 8
$ Año          <dbl> 2026, 2025, 2025, 2025, 2025, 2024, 2024, 2024, 2024, ~
$ Trimestre    <dbl> 1, 4, 3, 2, 1, 4, 3, 2, 1, 4, 3, 2, 1, 4, 3, 2, 1, 4, ~
$ Hogares      <dbl> 5978124, 5874111, 5835335, 5798402, 5750070, 5741731, ~
$ Comercial    <dbl> 507262, 526434, 534520, 552425, 563439, 574124, 599293~
$ Gobierno     <dbl> 33659, 31585, 28790, 28026, 28150, 28041, 27486, 27789~
$ Otros        <dbl> 62062, 54321, 65124, 70533, 74172, 77738, 80908, 93889~
$ Total        <dbl> 6581107, 6486451, 6463769, 6449386, 6415831, 6421634, ~
$ Total_calculado <dbl> 6581107, 6486451, 6463769, 6449386, 6415831, 6421634, ~

```

4.1 Resumen descriptivo

```

telefonía_fija_limpia %>%
  select(Hogares, Comercial, Gobierno, Otros, Total) %>%
  summary()

```

Hogares	Comercial	Gobierno	Otros
Min. :5741731	Min. : 507262	Min. :26497	Min. : 54321
1st Qu.:6307810	1st Qu.: 594245	1st Qu.:28041	1st Qu.:107378
Median :6933738	Median : 669618	Median :34155	Median :149460
Mean :7273173	Mean : 709129	Mean :32991	Mean :276839
3rd Qu.:8380800	3rd Qu.: 721607	3rd Qu.:36888	3rd Qu.:530163
Max. :9037000	Max. :1134427	Max. :39825	Max. :572106
Total			
Min. : 6415831			
1st Qu.: 7034211			
Median : 7626355			
Mean : 8292134			
3rd Qu.: 9805917			
Max. :10379749			

4.2 Evolución anual

```

telefonía_fija_limpia %>%
  group_by(Año) %>%
  summarise(Total_promedio = mean(Total, na.rm = TRUE), .groups = "drop")

```

```
# A tibble: 13 x 2
  Año Total_promedio
  <dbl>         <dbl>
1  2014      9603584.
2  2015     10025956.
3  2016     10252608.
4  2017     10252608.
5  2018      9717881.
6  2019      8028221
7  2020      7453867.
8  2021      7227959.
9  2022      7086614.
10 2023      7087000.
11 2024      6743200
12 2025      6453859.
13 2026      6581107
```

4.3 Evolución trimestral

```
telefonía_fija_limpia %>%
  arrange(Año, Trimestre) %>%
  select(Año, Trimestre, Total) %>%
  mutate(
    variacion_abs = Total - lag(Total),
    variacion_pct = round((Total - lag(Total)) / lag(Total) * 100, 2)
  )
```

```
# A tibble: 49 x 5
  Año Trimestre Total variacion_abs variacion_pct
  <dbl>   <dbl>   <dbl>         <dbl>         <dbl>
1  2014         1  9562231          NA          NA
2  2014         2  9548994     -13237     -0.14
3  2014         3  9613361      64367      0.67
4  2014         4  9689752      76391      0.79
5  2015         1 10086221     396469      4.09
6  2015         2  9991190    -95031     -0.94
7  2015         3 10050617      59427      0.59
8  2015         4  9975798    -74819     -0.74
9  2016         1 10239381     263583      2.64
10 2016         2 10379749     140368      1.37
# i 39 more rows
```

4.4 Proporción por tipo de cliente

```
telefonía_fija_limpia %>%
  summarise(
    Hogares_pct = mean(Hogares / Total) * 100,
    Comercial_pct = mean(Comercial / Total) * 100,
    Gobierno_pct = mean(Gobierno / Total) * 100,
    Otros_pct = mean(Otros / Total) * 100
  )
```

```
# A tibble: 1 x 4
  Hogares_pct Comercial_pct Gobierno_pct Otros_pct
    <dbl>         <dbl>         <dbl>         <dbl>
1      88.0          8.55          0.403          3.04
```

4.5 Accesos por provincia

```
corregir_escalas <- function(x) {
  ifelse(abs(x - round(x)) < 1e-6, x, round(x * 1000))
}

provincias_limpia <- read_excel(archivo_provincias, skip = 1) %>%
  mutate(
    across(c(Hogares, Total), ~ as.numeric(str_remove_all(as.character(.), "\\."))),
    across(c(Comercial, Gobierno, Otros), corregir_escalas),
    Total_calculado = Hogares + Comercial + Gobierno + Otros,
    diferencia = Total - Total_calculado
  )

provincias_limpia %>%
  select(Provincias, Total, Total_calculado, diferencia) %>%
  arrange(desc(abs(diferencia)))
```

```
# A tibble: 1,176 x 4
  Provincias      Total Total_calculado diferencia
  <chr>          <dbl>         <dbl>         <dbl>
1 Buenos Aires  3184068       3184068          0
2 Capital Federal 1425689       1425689          0
3 Catamarca      17021         17021           0
```

4	Chaco	43381	43381	0
5	Chubut	50786	50786	0
6	Córdoba	454943	454943	0
7	Corrientes	63700	63700	0
8	Entre Ríos	120623	120623	0
9	Formosa	36548	36548	0
10	Jujuy	17393	17393	0


i 1,166 more rows

```
provincias_ultimo <- provincias_limpia %>%
  filter(Año == 2026, Trimestre == 1) %>%
  arrange(desc(Total))

provincias_ultimo %>% select(Provincias, Total)
```

```
# A tibble: 24 x 2
  Provincias      Total
  <chr>          <dbl>
1 Buenos Aires  3184068
2 Capital Federal 1425689
3 Córdoba       454943
4 Santa Fe      376102
5 Mendoza       176391
6 Tucumán       127157
7 Entre Ríos    120623
8 Río Negro     72178
9 Neuquén       66867
10 Corrientes   63700
# i 14 more rows
```

```
ggplot(provincias_ultimo, aes(x = reorder(Provincias, Total), y = Total)) +
  geom_col(fill = "steelblue") +
  coord_flip() +
  labs(
    title = "Accesos a telefonía fija por provincia (2026-Q1)",
    x = "Provincia", y = "Cantidad de accesos"
  ) +
  theme_minimal()
```



5 Ejercicio 5. ARPU de telefonía móvil

```
if (!file.exists("Telefonía móvil Accesos Totales.csv") ||
    !file.exists("Telefonía móvil Ingresos.csv")) {
  stop("Faltan los CSV de telefonía móvil en: ", getwd())
}

accesos_movil <- read_csv("Telefonía móvil Accesos Totales.csv", show_col_types = FALSE) %>%
  rename(
    accesos_pospago = `Total de accesos pospago`,
    accesos_prepago = `Total de accesos prepago`,
    accesos_operativos = `Total de accesos operativos`
  ) %>%
  mutate(
    across(
      c(accesos_pospago, accesos_prepago, accesos_operativos),
      ~ as.numeric(str_remove_all(as.character(.), "\\\\"))
    )
  )
```

```

)

ingresos_movil <- read_csv("Telefonía móvil Ingresos.csv", show_col_types = FALSE) %>%
  mutate(
    Ingresos = Ingresos %>%
      str_remove("\\$") %>%
      str_remove_all("\\s") %>%
      str_remove_all("\\.") %>%
      str_replace(",", ".") %>%
      as.numeric()
  )

```

5.1 ARPU nominal (2020-2025)

Los ingresos están en miles de pesos.

```

arpu_datos <- accesos_movil %>%
  select(Año, Trimestre, accesos_operativos) %>%
  inner_join(ingresos_movil, by = c("Año", "Trimestre")) %>%
  arrange(Año, Trimestre) %>%
  mutate(A_barra = (accesos_operativos + lag(accesos_operativos)) / 2) %>%
  filter(Año >= 2020, Año <= 2025) %>%
  mutate(
    Ingresos_pesos = Ingresos * 1000,
    ARPU_nom = Ingresos_pesos / (A_barra * 3),
    periodo = Año + (Trimestre - 1) / 4
  )

arpu_datos %>% select(Año, Trimestre, Ingresos_pesos, A_barra, ARPU_nom)

```

A tibble: 24 x 5

	Año	Trimestre	Ingresos_pesos	A_barra	ARPU_nom
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	2020	1	72077147000	55771862	431.
2	2020	2	73538944000	55331766.	443.
3	2020	3	79634755000	54835304.	484.
4	2020	4	83479114000	54691893	509.
5	2021	1	93112153000	55608466.	558.
6	2021	2	104782020000	56664298.	616.
7	2021	3	117751925000	57344036.	684.
8	2021	4	127389786000	58439168	727.

```


9 2022      1 130454676000 59117368.    736.
10 2022     2 153032313000 59140051    863.
# i 14 more rows

```

```

ggplot(arpudatos, aes(x = periodo, y = ARPU_nom)) +
  geom_line(linewidth = 1, color = "darkgreen") +
  geom_point(size = 1.5, color = "darkgreen") +
  labs(
    title = "Evolución del ARPU nominal (telefonía móvil)",
    x = "Año", y = "ARPU nominal ($ por mes)"
  ) +
  theme_minimal()

```



5.2 Tipo de cambio y ARPU en dólares

```

url_dolar <- paste0(
  "https://apis.datos.gob.ar/series/api/series/?",
  "ids=168.1_T_CAMBIOR_D_0_0_26",
  "&start_date=2019-10-01",

```

```

"&end_date=2025-12-31",
"&collapse=month",
"&collapse_aggregation=avg",
"&format=csv"
)

dolar_mensual <- request(url_dolar) |>
  req_user_agent("Mozilla/5.0") |>
  req_perform() |>
  resp_body_raw() |>
  read_csv(show_col_types = FALSE)

tc_trimestral <- dolar_mensual %>%
  rename(TC = tipo_cambio_bna_vendedor) %>%
  mutate(
    Año = year(indice_tiempo),
    Trimestre = quarter(indice_tiempo)
  ) %>%
  group_by(Año, Trimestre) %>%
  summarise(TC_promedio = mean(TC), .groups = "drop")

arpu_datos <- arpu_datos %>%
  inner_join(tc_trimestral, by = c("Año", "Trimestre")) %>%
  mutate(ARPU_usd = ARPU_nom / TC_promedio)

arpu_datos %>% select(Año, Trimestre, ARPU_nom, TC_promedio, ARPU_usd)


```

```

# A tibble: 24 x 5
   Año Trimestre ARPU_nom TC_promedio ARPU_usd
  <dbl>   <dbl>   <dbl>   <dbl>   <dbl>
1  2020         1    431.     61.5     7.00
2  2020         2    443.     67.6     6.55
3  2020         3    484.     73.3     6.61
4  2020         4    509.     80.0     6.36
5  2021         1    558.     88.6     6.30
6  2021         2    616.     94.0     6.56
7  2021         3    684.     97.2     7.04
8  2021         4    727.    100.     7.23
9  2022         1    736.    107.     6.90
10 2022         2    863.    118.     7.32
# i 14 more rows

```

```
ggplot(arpudatos, aes(x = periodo, y = ARPU_usd)) +
  geom_line(linewidth = 1, color = "purple") +
  geom_point(size = 1.5, color = "purple") +
  geom_hline(yintercept = 6.5, linetype = "dashed", color = "red") +
  labs(
    title = "ARPU en dólares vs. promedio regional",
    subtitle = "Línea roja punteada = USD 6,5",
    x = "Año", y = "ARPU (USD/mes)"
  ) +
  theme_minimal()
```



6 Respuestas

6.1 Ejercicio 1

6. Sí. En el gráfico se observa que *Gilia* sp. y *Ranunculaceae* sp. tienen mayor emergencia en sitios con pastoreo, mientras que *Pappostipa* sp. y *Plantago patagonica* emergen más en sitios sin pastoreo.

8. El patrón del gráfico coincide con la descripción teórica del ejercicio.

6.2 Ejercicio 4

1. No se responde.
2. Entre 2014 y 2017 el promedio crece de unos 9,6 a 10,25 millones de accesos. Desde 2018 se observa un decaimiento hasta 2025. En 2026 hay una suba leve (6,58 millones), poco concluyente porque ese año tiene un solo trimestre.
3. Los accesos a telefonía fija crecieron entre 2014 y 2017, con el valor más alto (10.379.749 accesos) en el segundo trimestre de 2016 (valor que se repite en el segundo trimestre de 2017, según ENACOM). Después empezaron a bajar de forma constante. La caída más grande del período fue entre el último trimestre de 2018 y el primero de 2019: los accesos bajaron 15,1% (1.478.517 líneas menos) de un trimestre al siguiente. Luego la baja continuó más lento hasta 2025, con una suba leve en el primer trimestre de 2026.
4. El tipo de cliente con mayor proporción de líneas fijas es Hogares, con un 88% del total en promedio entre 2014 y 2026. Sigue Comercial (8,55%). Otros (3,04%) y Gobierno (0,40%) son una fracción chica del total.

6.3 Ejercicio 5

4. El ARPU en dólares se mantuvo cerca del promedio regional (USD 6,5) entre 2020 y 2023, con subas y bajas. A fines de 2023, con la devaluación del peso, cayó a unos USD 4,8, el valor más bajo del período. Las empresas seguían cobrando en pesos, pero esos pesos valían menos en dólares. La caída importa porque buena parte de lo que necesita una telefónica para la red (antenas, cables, equipos) se compra en dólares: si baja el ingreso en dólares, queda menos margen para invertir. Desde 2024 el ARPU se recuperó y superó los USD 7,5, por encima del promedio regional, lo que sugiere mejor capacidad de inversión en esa etapa.
5. El ARPU en dólares es la métrica más adecuada para este análisis: evita el efecto de la inflación, permite comparar con otros países y se relaciona mejor con la inversión en infraestructura, que en buena parte se paga en dólares.

El ARPU nominal no sirve tanto para este objetivo. Muestra los ingresos en pesos del día a día, pero no deja ver con claridad si el negocio mejoró o empeoró, porque los precios en pesos suben por inflación aunque al negocio no le vaya mejor.